

# EM算法参数估计

陈煜磊 ZY2103502

## 1 问题

一个袋子中三种硬币的混合比例为： $s_1, s_2$  与  $1 - s_1 - s_2$  ( $0 \leq s_i \leq 1$ )，三种硬币掷出正面的概率分别为： $p, q, r$ 。指定系数  $s_1 = 0.2, s_2 = 0.3, p = 0.1, q = 0.9, r = 0.5$ ，生成  $N$  个投掷硬币的结果（由 01 构成的序列，其中 1 为正面，0 为反面），利用最大期望算法（Expectation-maximization algorithm，EM 算法）来对参数进行估计并与预先假定的参数进行比较。

## 2 原理

EM 算法由 Dempster 等<sup>[1]</sup>在 1977 年提出，是在概率模型中寻找参数最大似然估计或者最大后验估计的算法，其中概率模型依赖于无法观测的隐变量。算法经过两个步骤交替进行计算：

1. 初始化分布参数
2. 重复直到收敛：
  1. E 步骤：根据参数的假设值，给出未知变量的期望估计，应用于缺失值。
  2. M 步骤：根据未知变量的估计值，给出当前的参数的极大似然估计。

Wu<sup>[2]</sup>证明了 EM 算法是收敛的，但不能保证收敛到极大值点，因此算法中初值选择很重要。

设  $y_j$  是第  $j$  次实验抛硬币的观测数据， $z_i = (\alpha_i, \beta_i)$  为第  $i$  次迭代中的隐变量，其中  $\alpha_i$  表示摸到硬币 A 的概率， $\beta_i$  表示摸到硬币 B 的概率，模型参数  $\theta = (s_1, s_2, p, q, r)$ ，第  $i$  次迭代时参数估计为  $\theta^{(i)} = (s_1^{(i)}, s_2^{(i)}, p^{(i)}, q^{(i)}, r^{(i)})$ 。观测数据的似然函数：

$$P(Y|\theta) = \prod_{j=1}^n [s_1 p^{y_j} (1-p)^{1-y_j} + s_2 q^{y_j} (1-q)^{1-y_j} + (1-s_1-s_2) r^{y_j} (1-r)^{1-y_j}] \quad (1)$$

观测数据  $Y$  关于当前参数估计  $\theta^{(i)}$  的对数似然函数为：

$$L(\theta) = \log P(Y|\theta) = \log \left( \sum_Z P(Y|Z, \theta) P(Z|\theta) \right) \quad (2)$$

我们希望迭代参数能使得  $L(\theta)$  极大化，取两次迭代的差值：

$$\begin{aligned} L(\theta) - L(\theta^{(i)}) &= \log \left( \sum_Z P(Z|Y, \theta^{(i)}) \frac{P(Y|Z, \theta) P(Z|\theta)}{P(Z|Y, \theta^{(i)})} \right) - \log P(Y|\theta^{(i)}) \\ &\geq \sum_Z P(Z|Y, \theta^{(i)}) \log \frac{P(Y|Z, \theta) P(Z|\theta)}{P(Z|Y, \theta^{(i)})} - \log P(Y|\theta^{(i)}) \\ &= \sum_Z P(Z|Y, \theta^{(i)}) \log \frac{P(Y|Z, \theta) P(Z|\theta)}{P(Z|Y, \theta^{(i)}) P(Y|\theta^{(i)})} \end{aligned} \quad (3)$$

则迭代过程可表示为：

$$\begin{aligned} \theta^{(i+1)} &= \arg \max_{\theta} \left( L(\theta^{(i)}) + \sum_Z P(Z|Y, \theta^{(i)}) \log \frac{P(Y|Z, \theta) P(Z|\theta)}{P(Z|Y, \theta^{(i)}) P(Y|\theta^{(i)})} \right) \\ &= \arg \max_{\theta} \left( \sum_Z P(Z|Y, \theta^{(i)}) \log (P(Y|Z, \theta) P(Z|\theta)) \right) \\ &= \arg \max_{\theta} \left( \sum_Z P(Z|Y, \theta^{(i)}) \log P(Y, Z|\theta) \right) \end{aligned} \quad (4)$$

定义 Q 函数：

$$Q(\theta, \theta^{(i)}) \triangleq \sum_Z P(Z|Y, \theta^{(i)}) \log P(Y, Z|\theta) \quad (5)$$

则问题转化为  $\arg \max_{\theta} Q(\theta, \theta^{(i)})$ 。代入本问题，得：

$$Q(\theta, \theta^{(i)}) = \sum_{j=1}^n \{ \alpha_j^{(i+1)} [\log s_1 + y_j \log p + (1-y_j) \log (1-p)] + \beta_j^{(i+1)} [\log s_2 + y_j \log q + (1-y_j) \log (1-q)] + (1-\alpha_j^{(i+1)} - \beta_j^{(i+1)}) [\log (1-s_1-s_2) + y_j \log r + (1-y_j) \log (1-r)] \}$$

## • 2.1 E 步骤

已知第  $i$  次迭代得参数估计为  $\theta^{(i)}$ ，在该参数下观测数据  $y_j$  来自硬币 A 的概率为：

$$\alpha_j^{(i+1)} = \frac{s_1^{(i)}(p^{(i)})^{y_j}(1-p^{(i)})^{1-y_j}}{s_1^{(i)}(p^{(i)})^{y_j}(1-p^{(i)})^{1-y_j} + s_2^{(i)}(q^{(i)})^{y_j}(1-q^{(i)})^{1-y_j} + (1-s_1^{(i)}-s_2^{(i)})(r^{(i)})^{y_j}(1-r^{(i)})^{1-y_j}} \quad (7)$$

来自硬币 B 的概率为：

$$\beta_j^{(i+1)} = \frac{s_2^{(i)}(q^{(i)})^{y_j}(1-q^{(i)})^{1-y_j}}{s_1^{(i)}(p^{(i)})^{y_j}(1-p^{(i)})^{1-y_j} + s_2^{(i)}(q^{(i)})^{y_j}(1-q^{(i)})^{1-y_j} + (1-s_1^{(i)}-s_2^{(i)})(r^{(i)})^{y_j}(1-r^{(i)})^{1-y_j}} \quad (8)$$

## • 2.2 M 步骤

要极大化  $Q(\theta, \theta_i)$ ，需对参数求偏导。对  $s_1, s_2$ ：

$$\frac{\partial Q}{\partial s_1} = \sum_{j=1}^n \left[ \frac{\alpha_j^{(i+1)}}{s_1} - \frac{1 - \alpha_j^{(i+1)} - \beta_j^{(i+1)}}{1 - s_1 - s_2} \right] = 0 \quad (9)$$

$$\frac{\partial Q}{\partial s_2} = \sum_{j=1}^n \left[ \frac{\beta_j^{(i+1)}}{s_2} - \frac{1 - \alpha_j^{(i+1)} - \beta_j^{(i+1)}}{1 - s_1 - s_2} \right] = 0 \quad (10)$$

解得  $s_1 = \frac{1}{n} \sum_{j=1}^n \alpha_j^{(i+1)}$ ,  $s_2 = \frac{1}{n} \sum_{j=1}^n \beta_j^{(i+1)}$

再对  $p, q, r$  求偏导，由：

$$\frac{\partial Q}{\partial p} = \sum_{j=1}^n \alpha_j^{(i+1)} \left[ \frac{y_j}{p} - \frac{1 - y_j}{1 - p} \right] = 0 \quad (11)$$

得  $p^{(i+1)} = \frac{\sum_{j=1}^n \alpha_j^{(i+1)} y_j}{\sum_{j=1}^n \alpha_j^{(i+1)}}$ 。同理有  $q^{(i+1)} = \frac{\sum_{j=1}^n \beta_j^{(i+1)} y_j}{\sum_{j=1}^n \beta_j^{(i+1)}}$ ,  $r^{(i+1)} = \frac{\sum_{j=1}^n (1 - \alpha_j^{(i+1)} - \beta_j^{(i+1)}) y_j}{\sum_{j=1}^n (1 - \alpha_j^{(i+1)} - \beta_j^{(i+1)})}$

再由迭代得参数重复进行 E-M 步骤，直到达到最大迭代次数或参数收敛（即  $\|\theta^{(i+1)} - \theta^{(i)}\| < \varepsilon$ ）。

## 3 代码

首先根据参数生成 N 次投掷硬币的观测结果：

```
def data_gen(s1, s2, p, q, r, N):
    data = []
    for i in range(N):
        coin = random.random()
        if 0 <= coin < s1:
            side = np.random.binomial(1,p)
        elif s1 <= coin < s1 + s2:
            side = np.random.binomial(1,q)
        else:
            side = np.random.binomial(1,r)
        data.append(side)
    return data
```

再给定初始参数估计，观测数据和迭代终止条件，运行 EM 算法：

```
def EM(theta, e, y, max_epoch):
    s1 = theta[0]
    s2 = theta[1]
    p = theta[2]
    q = theta[3]
    r = theta[4]
    N = len(y)
    i = 0
    while(i < max_epoch and threshold >= e):
        # Expectation
        a = np.random.rand(N)
        b = np.random.rand(N)
        for j in range(N):
```

```

a[j] = (s1*pow(p,y[j])*pow(1-p,1-y[j]))/(s1*pow(p,y[j])*pow(1-p,1-y[j])+s2*pow(q,y[j])*pow(1-q,1-y[j])+(1-s1-s2)*pow(r,y[j])*pow(1-r,1-y[j]))
b[j] = (s2*pow(q,y[j])*pow(1-q,1-y[j]))/(s1*pow(p,y[j])*pow(1-p,1-y[j])+s2*pow(q,y[j])*pow(1-q,1-y[j])+(1-s1-s2)*pow(r,y[j])*pow(1-r,1-y[j]))
# Maximization
s1_next = 1/N * sum(a)
s2_next = 1/N * sum(b)
p_next = sum([a[j]*y[j] for j in range(N)]) / sum(a)
q_next = sum([b[j]*y[j] for j in range(N)]) / sum(b)
r_next = sum([(1-a[j]-b[j])*y[j] for j in range(N)]) / sum([(1-a[j]-b[j]) for j in range(N)])
# Threshold
threshold = np.linalg.norm(np.array([s1-s1_next,s2-s2_next,p-p_next,q-q_next,r-r_next]),ord = 2)
s1 = s1_next
s2 = s2_next
p = p_next
q = q_next
r = r_next
i += 1
print(i,[s1,s2,p,q,r])
return s1,s2,p,q,r

```

## 4 实验结果

给定初值  $\theta^{(0)} = (0.4, 0.5, 0.2, 0.6, 0.8)$ ，取最大迭代次数 10，终止阈值  $1 \times 10^{-20}$ ，得

```

1 [0.42512077294685996, 0.48309178743961356, 0.163636363636366, 0.54, 0.7578947368421054]
2 [0.42512077294685996, 0.48309178743961356, 0.163636363636364, 0.54, 0.7578947368421064]
3 [0.4251207729468601, 0.48309178743961356, 0.163636363636355, 0.54, 0.7578947368421068]
4 [0.4251207729468601, 0.48309178743961356, 0.163636363636358, 0.54, 0.7578947368421071]
5 [0.4251207729468601, 0.48309178743961356, 0.163636363636355, 0.54, 0.7578947368421072]
6 [0.4251207729468601, 0.48309178743961356, 0.163636363636355, 0.54, 0.7578947368421071]
7 [0.4251207729468601, 0.48309178743961356, 0.163636363636355, 0.54, 0.7578947368421071]

```

与真值  $\theta = (0.2, 0.3, 0.1, 0.9, 0.5)$  相去甚远。这是因为EM算法只能保证参数估计序列收敛到对数似然函数序列的稳定点，不能保证收敛到极大值点。

## 5 参考文献

- [1] A. P. Dempster, N. M. Laird, and D. B. Rubin, "Maximum likelihood from incomplete data via the EM algorithm," *Journal of the Royal Statistical Society: Series B (Methodological)*, vol. 39, no. 1, pp. 1–22, 1977, doi: 10.1111/j.2517-6161.1977.tb01600.x.
- [2] C. F. J. Wu, "On the Convergence Properties of the EM Algorithm," *The Annals of Statistics*, vol. 11, no. 1, pp. 95–103, 1983, doi: 10.1214/aos/1176346060.
- [3] 李航, 统计学习方法. 清华大学出版社, 2012.